



INSTITUTO FEDERAL
Triângulo Mineiro
Campus Paracatu

INSTITUTO FEDERAL DO TRIÂNGULO MINEIRO -
CAMPUS PARACATU
Curso: Tecnologia em Análise e Desenvolvimento
de Sistemas

Disciplina: Programação de Computadores II
Professor: Josimar Viana

Trabalho Prático 03 (15 pontos)

Processamento de Texto

Este projeto visa implementar um verificador ortográfico simples, que verifica se as palavras de um texto de entrada estão em um dicionário predefinido e sugere correções para as palavras não encontradas.

O verificador ortográfico

O verificador de ortografia recebe um texto de entrada e verifica se suas palavras estão em um dicionário. A saída deve **reproduzir fielmente o texto de entrada** (inclusive espaços e quebras de linha), mas colocando entre colchetes as palavras não encontradas no dicionário.

Por exemplo, para esta entrada:

Para que o processador possa interromper a execução de uma tarefa e retornar a ela mais tarde, sem corromper seu estado interno, é necessário definir operações para salvar e restaurar o contexto da tarefa.

===

O ato de salvar os valores do contexto atual em seu TCB e possivelmente restaurar o contexto de outra tarefa, previamente salvo em outro TCB, é denominado "troca de contexto".

O programa deve gerar esta saída:

Para que o [processador] possa interromper a execução de uma tarefa e retornar a ela mais tarde, sem corromper seu estado interno, é necessário definir operações para salvar e [restaurar] o contexto da tarefa.

===

O ato de salvar os valores do contexto atual em seu [TCB] e possivelmente restaurar o contexto de outra tarefa, previamente salvo em outro [TCB], é denominado "troca de contexto".

Consideram-se como palavras as sequências contíguas de letras (A-Z, a-z) com ou sem acentos e as cedilhas; os demais caracteres (números, espaços e outros símbolos) não fazem parte de palavras.

Sugestões

Um bom verificador ortográfico deve **sugerir correções** para as palavras incorretas. Programe o verificador para informar as palavras conhecidas mais próximas das palavras não encontradas no dicionário, como mostra este exemplo:

Para que o [pocessorador (processador)] possa interromper a execução de uma tarefa e retornar a ela mais tarde, sem corromper seu estado interno, é necessário definir operações para salvar e [restaurar (restaurar)] o contexto da tarefa.

===

O ato de salvar os valores do contexto atual em seu [TCB (aba)] e possivelmente restaurar o contexto de outra tarefa, previamente salvo em outro [TCB (aba)], é denominado "troca de contexto".

Para encontrar a palavra mais próxima no dicionário, sugere-se usar a distância Levenshtein, que permite calcular a distância entre duas strings.

O algoritmo de Levenshtein é lento, portanto evite comparar palavras de comprimentos muito diferentes (por exemplo, evite calcular a distância entre “uva” e “laranja”).

Atividade

A implementação deve atender os seguintes requisitos:

- Funcionar corretamente com os exemplos deste documento 🍌
- O dicionário deve ser totalmente carregado em um vetor de palavras na memória RAM antes de ser usado, usando alocação dinâmica (os mais ousados podem tentar implementar este projeto usando uma árvore de prefixos).
- A localização das palavras no dicionário deve usar um algoritmo de busca binária.
- O executável deve se chamar **ortografia**.
- Processar o arquivo **brascubas.txt** em **menos de 1 segundo** (com sugestões desativadas).

Para medir o tempo de execução do programa, use o comando **time**:

```
time ./ortografia -i brascubas.txt -o output.txt
```

Arquivos a entregar ao professor:

- **ortografia.c** : programa principal
- **dicionario.c** : funções relativas ao dicionário (carregar o dicionário na memória, verificar se uma palavra está no dicionário, etc);
- **dicionario.h** : interface (protótipos) das funções implementadas em **dicionario.c**;
- **Makefile**

Dica: as funções da biblioteca C padrão (StdLib) podem facilitar a implementação de seu programa:

- Acesso a arquivos: **fopen**, **fclose**, **fgetchar**, **fscanf**, **feof**, ...
- Uso de caracteres e strings
largas: **getwchar**, **putwchar**, **iswalph**, **towlower**, **wcsl**, **fwscanf**, **wscpy**, **wscasecmp**, ...
- Busca binária: **bsearch**
- Ordenação: **qsort**

Consulte as páginas de manual para aprender a usar essas funções.

Sugestões de implementação

Por pseudocódigo:

```
ler o dicionário em um vetor de palavras

c = ler caractere da entrada

enquanto não for o fim da entrada faça

    // avançar até encontrar uma letra ou o fim da entrada

    enquanto (c não for uma letra) e (não for o fim da entrada) faça

        escrever c em stdout

        c = ler caractere da entrada

    fim enquanto

    // encontrou uma letra, ler a palavra inteira

    palavra = ""

    enquanto (c for uma letra) e (não for o fim da entrada) faça

        palavra = palavra + c

        c = ler caractere da entrada

    fim enquanto

    // tratar a palavra encontrada

    se palavra <> "" então

        se minúscula(palavra) está no dicionário então

            escrever palavra na saída

        senão

            escrever "[", palavra, "]" na saída

    fim se

fim se

fim enquanto
```